Analyse statistique - Séance 4 : Enquêtes par questionnaire et représentativité statistique

Aubin Poissonnier-Beraud

Villes et environnements urbains - Université Lumière Lyon 2

2023

Population et échantillon

Thomé Cécile, « "On fait juste attention." La mesure du retrait comme méthode contraceptive dans les enquêtes en France depuis les années 1970 », Population, 2023, vol. 78, n1, p. 29-50.

- Pourquoi les premières enquêtes des années 1960 n'étaient pas de « véritables enquêtes » ?
- Quel principal obstacle ont rencontré les enquêtes des années 1970 pour la mesure du retrait ?
- Quelles stratégies d'enquête ont permis ou permettraient d'améliorer la mesure de cette méthode contraceptive ?

Population et mesure du retrait

Tableau A.1. Mesure du retrait dans neuf enquêtes françaises entre 1970 et 2016

	lableau A.I. Westife du l'etrait dans neul enquetes trançaises entre 1970 et 2010							
Année	Nom de l'enquête	Population interrogée	Mesure du retrait (en gras, la période concernée)	Désignation de la méthode (le cas échéant)	Méthode considérée comme principale dans le traitement des données	Taux de recours au retrait comme méthode principale (chez les personnes concernées)		
					des données	Hommes	Femmes	
1970	Enquête Simon	1 375 femmes et 1 250 hommes de 20 ans et plus	Il ne s'agit pas de la méthode utilisée actuellement, mais de méthodes ayant déjà été utilisées au cours de la vie. Un tableau des méthodes était proposé.	« Interruption du rapport avant l'éjaculation »	-	50 % (au cours de la vie)	46 % (au cours de la vie)	
1971	Enquête sur la régulation des naissances (ined / Insee)	2890 femmes non célibataires ayant moins de 47 ans	Une première question ouverte est posée concernant ce qu'on peut faire pour éviter une naissance », puis des questions sur les informations médicales reçues sur le sujet. Puis : • Depuis que vous étes mardse, avez-vous fait quelque chose, vous-même ou votre mart, pour éviter une naissance ? (51 oui) Qu'avez-vous fait ? (donnez-moi le numéro de la liste) ». Le retrait est situé en 3° position.	« Retrait, l'homme se retire à temps »	Déclaratif	-	30 % (depuis le mariage)	
1978	Enquête mondiale de fécondité (Ined/Insee)	3011 femmes de 20 à 44 ans, mariées ou non	Un paragraphe introductif visant à normaliser l'utilisation d'une contraception est la uze enquétées. Les méthodes sont citées et explicitées (le retrait cité en 2º position) pour en teste la connaissance, puis demande à l'enquétée; « Est-ce que votre mari (parteniarie) et usus-même employar actuellement une méthode pour éviter d'avoir un enfant? », et si oul aquelle ou lesquéles. En cas de reponse négative, une question de rattrapage est prévue; « N voius, ni vote mari, ne prenez aucune précaution? »	L'homme peut aussi pratiquer le retrait, C'est-à-dire se retirer à temps (avant l'éjaculation) »	Celle utilisée en milieu de cycle. Si plusieurs méthodes sont déclarées, hiérarchisation (retrait 6° sur 8).	-	18 % (actuellement)	
1988	Enquête fécondité (ined/inserm)	3 188 femmes de 18 à 49 ans	Les méthodes sont citées et explicitées (le retait est cité en 2º position) pour en testé ne comaissance et l'utilisation au cours de la vie, puis on demande à l'enquêtée : « Employez-vous actuellement une méthode, vous ouvier conjoint, pour éviter d'avoir un enfant? », et si ou la aquelle. En cas de réponse négative une question de rattrapage est prévue : « Ni vous, ni votre conjoint ne prenez aucune précaution ? »	« L'homme peut aussi pratiquer le retrait, c'est-à-dire se retirer à temps (avant l'éjaculation) »	Celle utilisée en milieu de cycle. Si plusieurs méthodes déclarées, hiérarchisation (retrait 6° sur 10).	-	9 % (actuellement)	

Population et mesure du retrait

Tableau A.1 (suite). Mesure du retrait dans neuf enquêtes françaises entre 1970 et 2016

Année	Nom de l'enquête	Population interrogée	Mesure du retrait (en gras, la période concernée)	Désignation de la méthode (le cas échéant)	Méthode considérée comme principale dans le traitement	Taux de recours au retrait comme méthode principale (chez les personnes concernées)	
				(le cas echeant)	des données	Hommes	Femmes
2000	Cocon 2000 « Cohorte sur la contraception » Inserm/Ined	2 863 femmes ayant entre 18 et 44 ans	Toutes les méthodes sont citées (le retrait est cité en 2e position), question sur la « méthode actuelle ». Une question de rattrapage était prévue si aucune méthode n'était déclarée : « Pouvez-vous me dire si ces phrases vous concernent en ce moment » : « 7. Mon partenaire se retite avant la fin du rapport ».	« Retrait du partenaire avant l'éjaculation »	Hiérarchisation	-	2,1 % (actuellement)
2006	CSF « Contexte de la sexualité en France » Ined/Inserm	6824 femmes et 5540 hommes de 18 à 69 ans	Question concernant le dernier rapport sexuel. Les méthodes ne sont pas citées, mais il y a une question de rattrapage ouverte : « Pourquoi n'utilisiez-vous pas de méthodes pour éviter une grossesse? » dont l'une des modalités est « N'utilise pas de méthode, mais fait quand même attention »	-	-	3,3 % (dernier rapport sexuel)	2,9 % (dernier rapport sexuel)
2010	Fecond 2010 « Fécondité - contraception - dysfonctions sexuelles » Inserm	5275 femmes et 3373 hommes de 15 à 49 ans	Toutes les méthodes sont citées (le retrait est cité en 5° position) pour déterminer l'utilisation au cours de la vie et l'utilisation « actuellement ».	« Retrait du partenaire avant l'éjaculation »	Déclaratif	2,3 % (7,7 % en tout) (actuellement)	3,6 % (actuellement)
2013	Fecond 2013 « Fécondité - contraception - dysfonctions sexuelles » Inserm	4453 femmes et 1587 hommes de 15 à 49 ans	Les méthodes ne sont pas citées, mais les « méthodes naturelles » sont mentionnées dans la question: «Actuellement, est-ce que vous ou votre parteniaire utilisez un moyen pour éviter une grossesse y compris une méthode naturale, et so un le us lesquels ? ». Une question de rattrapage méthonne le retrait : « Parmi les phrases suivantes, lesquelles vous concernent actuellement ? [] S. Vousvotre partenaire se retire vand répoudation [] »	-	Déclaratif	4,5 % (actuellement)	5,1 % (actuellement)
2016	Baromètre santé, volet « Contraception »	4315 femmes ågées de 15 à 49 ans	Les methodes ne sont pas citées, mais les « méthodes naturelles » sont mentionnées dans la question : « Actuellement, est-ce que vous ou votre partenaire utilizez une méthode pour éviter une grossesse, y compris les méthodes naturelles, et si oui laquelle ? ». Il n'y a pas de question de rattrapage. hine Rahib d'avoir fourni ce chiffre.	-	Hiérarchisation (retrait 12e sur 17)	-	2,7 % ^(a) (actuellement)

Sources

Les premières slides de ce powerpoint ont été récupérées sur le site de Martin Chevalier, administrateur à l'INSEE. Tous ses supports de cours sont disponibles en accès libres sur le site : https://teaching.slmc.fr/.

Qu'est-ce qu'une enquête statistique ?

Quelques éléments de définition

Une enquête statistique est un dispositif d'observation qui :

- porte sur un échantillon d'unités (ménages, entreprises, etc.) considérées comme représentatives d'une population,
- repose sur un questionnaire et un ensemble de codifications (modalités de réponse pré-codées, nomenclatures),
- permet un traitement quantitatif des données recueillies

Qu'est-ce qu'une enquête statistique ?

Exemple : l'enquête Emploi en continu

L'enquête Emploi en continu (EEC) est un des dispositifs les plus importants de la statistique publique :

- échantillon rotatif, environ 100 000 personnes de 15 ans ou plus interrogées chaque trimestre (en France métropolitaine),
- questionnaire de 50 pages, mesure du chômage selon la définition du Bureau international du travail (BIT),
- publication trimestriel du taux de chômage France métropolitaine, un des principaux indicateurs économiques nationaux et internationaux.

Enquête statistique et base de données

Toute enquête statistique peut être abordée comme une base de données mais toute base de données ne présente pas les caractéristiques d'une enquête statistique.

Exemples

- Données administratives : déclarations annuelles de données sociales (DADS), fichiers de demandeurs d'emploi, fichier des infractions police gendarmerie, etc.
- « Mégadonnées » (big data) collectées automatiquement : données de téléphone portable, données de caisse des supermarchés, etc

Ces bases de données n'ont pas été pensées à l'origine pour produire de l'information statistique : leur exploitation est complexe et nécessite des précautions

Les enjeux liés à l'élaboration du questionnaire

Construire un questionnaire

L'élaboration du questionnaire d'une enquête statistique constitue un arbitrage entre deux contraintes contradictoires :

- ▶ l'exhaustivité des thèmes abordés, précision de l'information collectée, comparabilité avec d'autres dispositifs existants,
- ▶ la durée de passation, caractère compréhensible des questions et absence d' « imposition de problématique ».

Comprendre les contraintes de l'élaboration d'un questionnaire permet de comprendre les choix qui ont été faits et d'être à même de « donner du sens aux données ».

L'élaboration du questionnaire

Les principales contraintes dans la rédaction d'un questionnaire

Longueur du questionnaire : fortement dépendant du mode de collecte (cf. infra).

Choix du vocabulaire et formulation des questions :

- être compris par le public visé (exemple : enquête de l'UNICEF sur les enfants de 6 à 18 ans),
- ▶ ne pas influencer le répondant (biais de désirabilité, de cohérence, etc.).

Choix des questions et de leur forme :

- recueillir l'information la plus plus précise prossible,
- ètre économe en temps et en énergie pour le ou la répondant.e,
- ▶ l'important de l'ordre des questions

L'élaboration du questionnaire

Les types de questions

Les questions fermées sous forme de réponse unique, réponses multiples ou de classement des préférences :

- Facilité de codification et de traitement, rapidité pour l'enquêté
- ► Information restrictive et sans nuance, risque de réponse « au hasard » ou de tentative de deviner |a « bonne » réponse.

Les questions ouvertes :

- Grande liberté pour l'enquêté, possibilité d'obtenir des réponses non-prévues à la conception de questionnaire, exploitations originales (statistique textuelle).
- Difficulté de traitement, relativement coûteux pour l'enquêté (risque de non-réponse partielle).

La collecte

Une phase cruciale de l'enquête

La collecte va permettre de juger du succès d'une enquête. Son déroulement détermine le niveau de (non-)réponse à l'enquête, ainsi que la qualité des informations recueillies. Le choix du mode de collecte, effectué très en amont, est déterminant.

- ▶ en face-à-face (assistée par ordinateur)
- par téléphone
- par courrier et par dépôt-retrait
- par internet

La collecte

Le rôle des enquêteurices

L'enquêteur a un rôle important à jouer pour assurer le succès d'une enquête, en particulier quand il ou elle s'écarte des consignes de collecte :

- création d'une relation de confiance avec l'enquêté : ne pas montrer la lettre officielle mais parler de la télévision ou du sport, etc.
- reformuler ou passer des questions « stupides » : questions non-comprises, questions absurdes.

Statistiques descriptives et inférentielles

La méthode d'enquête par questionnaire s'inscrit dans un type de raisonnement statistique particulier, la représentativité, qui se fixe au début du XXe siècle.

- Les statistiques descriptives correspondent (dans un sens restreint) aux calculs réalisés sur des populations exhaustives.
- On appelle population de référence l'agrégat que l'on souhaite étudier : les étudiant es, les entreprises du CAC40, les député es de l'Assemblée Nationale etc.
- Les statistiques inférentielles correspondent aux opérations réalisées sur une partie de la population de référence, appelée l'échantillon, dans le but de tirer des conclusions fiables sur celle-ci. La fiabilité de nos affirmations dépend de la représentativité de notre échantillon ce qui implique de mettre en place des procédures d'échantillonnage et de pondération adéquates et de ses effectifs.
- Attention, un échantillon représentatif n'est pas une miniature de la population de référence. La représentativité dépend des méthodes d'échantillonnage et de redressement; ses définitions sont multiples.

La pondération

La pondération, soit le fait d'associer des poids (coefficients) aux individus statistiques, renvoie à cet objectif de représentativité.

Les méthodes d'échantillonnage

Les méthodes d'échantillonnage permettent de construire des échantillons à partir d'une populaiton.

- Le plan de sondage décrit la façon dont les individus ont été sélectionnés : aléatoirement, par quotas, par effets boule de neige etc.
- Le poids d'un individu correspond au nombre d'individus que l'individu de l'échantillon représente dans la population. Si l'on interroge 1 individu sur 100, le poids est alors de 100.
- ▶ Le plan de sondage peut adopter des stratégies pour maximiser l'information sans augmenter la taille de l'échantillon. Le principe de textcolororangela stratification consiste par exemple à intentionnellement sur-sélectionner les individus rares. Cette sur-sélection risque d'introduire un biais qui sera compensé par des poids inverses à la probabilité d'inclusion des individus.

Les méthodes de redressement

Par ailleurs, tout un ensemble de méthodes de redressement post-collecte permettent de corriger certains biais que l'on connaît. La correction de la non-réponse ou le redressement par *quotas* en sont des cas classiques. Elles se traduisent aussi par une modificatin des poids.

L'estimation de paramètres

- L'essentiel de l'analyse quantitative en science sociale repose sur l'estimation de paramètres à l'aide d'estimateurs ainsi que sur l'élaboration de modèles confirmés ou infirmés par des tests d'hypothèse.
- On peut vouloir décrire la structure d'âge d'une population en calculant la moyenne de l'âge (le paramètre M). Comme on dispose rarement d'information sur l'ensemble de la population, on réalise une estimation de la valeur réelle du paramètre grâce à un outil statistique, la moyenne observée (m). La théorie statistique permet de construire des intervalles de confiance renseignant sur la qualité de cette estimation. Elle peut être très précise ou au contraire imprécise.
- ▶ On peut vouloir savoir si le niveau de qualification professionnelle est dépendant du genre, c'est-à-dire si le niveau de qualification diffère en fonction du genre des individus. On doit ici aussi souvent partir d'un échantillon observé et mettre en place des thèses d'hypothèse pour conclure, selon un certain niveau de risque ou seuil de confiance, s'il existe ou non un lien entre les variables étudiées.

La typologie des familles

T	1	c		-1	-11 ^	2002
Typologie	des	tamilles	nar	classe	d.ade	en 2003

	Type de famille (en %)				
Catégorie d'âge	pas de frères et soeurs	1 à 3 frères et soeurs	plus de 3 frères et soeurs		
18 à 30 ans	9%	70%	20%		
31 à 60 ans	7%	55%	38%		
61 ans et plus	14%	57%	29%		
Ensemble	9%	59%	32%		

Lecture : en 2003, 7% des personnes âgées de 31 à 60 ans n'avaient pas de frères et soeurs. Dans l'ensemble, 9% de la population française toutes catégories d'âge confondues n'avaient pas de frères et soeurs

Champ : personnes majeures habitant en France métropolitaine

Source : Histoire de Vie 2003 (N = 2000) | A. POISSONNIER | 2023

- ▶ Les personnes âgées de 18 à 30 ans sont sur-représentées parmi les familles d'1 à 3 frères et soeurs (70% contre 59% dans l'ensemble) et sous-représentées parmi les familles de plus de 3 frères et soeurs (20% contre 32% dans l'ensemble).
- Les personnes âgées de 31 à 60 ans sont sous-représentées parmi les familles d'1 à 3 frères et soeurs (55% contre 59% dans l'ensemble) et sur-représentées parmi les familles de plus de 3 frères et soeurs (38% contre 32% dans l'ensemble).

L'incertitude des estimations

La valeur réelle des proportions estimées n'est pas connue mais la théorie statistique permet de mesurer l'incertitude. Cette mesure permet de se demander : les variations potentielles de notre estimation sont-elles tellement grandes que les écarts observés entre catégories s'annulent ?

Typologie des familles par classe d'âge en 2003

	Type de famille (en %)					
Catégorie d'âge	pas de frères et soeurs	1 à 3 frères et soeurs	plus de 3 frères et soeurs			
18 à 30 ans	9% ± 2%	70% ± 0%	20% ± 1%			
31 à 60 ans	7% ± 1%	55% ± 0%	38% ± 0%			
61 ans et plus	14% ± 1%	57% ± 0%	29% ± 1%			
Ensemble	9%	59%	32%			

Lecture : en 2003, 7% des personnes âgées de 31 à 60 ans n'avaient pas de frères et soeurs. Dans l'ensemble, 9% de la population française toutes catégories d'âge confondues n'avaient pas de frères et soeurs

Champ : Individus de 18 ans et plus habitant en France métropolitaine Source : Histoire de Vie 2003 (N = 2000) | A. POISSONNIER | 2023

Le test du Khi2

Le test du Khi2 sert à tester la dépendance entre des variables catégorielles à plusieurs modalités. Il repose sur une idée simple : si les effectifs du tri croisé de deux variables sont très différents des effectifs qu'on devrait observer si les deux variables étaient indépendantes, alors on peut raisonnablement conclure qu'elles n'ont pas d'effets l'une sur l'autre. Voilà pourquoi on part d'abord du tableau de contingence qui présente les effectifs observés du croisement de deux variables.

Tableau de contingence : effectifs observés						
		Type de famille				
Catégorie d'âge	pas de frères et soeurs	1 à 3 frères et soeurs	plus de 3 frères et soeurs	Ensemble		
18 à 30 ans	33	242	76	351		
31 à 60 ans	72	616	473	1 161		
61 ans et plus	62	260	166	488		
Ensemble	167	1118	715	2000		

Les effectifs marginaux

Il faut par la suite adopter un raisonnement conditionnel : si les deux variables étaient indépendantes, quels seraient nos effectifs ? Ce sont les effectifs marginaux (les totaux d'ensemble) qui nous permettent de calculer ces valeurs.

- ▶ On sait que la catégorie d'âge 18 à 30 ans représente $\frac{351}{2000} = 17,55\%$ de la population.
- ▶ On sait que les familles uniques représentent $\frac{167}{2000} = 8,35\%$ de la population.
- Par déduction, parmi les 18-30 ans, soit 17,55% des 2000 individus, il devrait y en avoir 8,35% qui appartiennent à une famille unique. On obtient 29 individus.

Tableau de contingence : effectifs observés							
		Type de famille					
Catégorie d'âge	pas de frères et soeurs	pas de frères et 1 à 3 frères et soeurs soeurs		Ensemble			
18 à 30 ans	33	242	76	351			
31 à 60 ans	72	616	473	1 161			
61 ans et plus	62	260	166	488			
Ensemble	167	1 118	715	2000			

Les effectifs théoriques

Le tableau des effectifs théoriques contient bien de nouvelles valeurs pour les cases des catégories, mais les mêmes valeurs pour les cases d'ensemble. Il faut maintenant mesurer à quel point ces deux tableaux diffèrent : on calculera simplement des écarts.

Tableau de contingence : effectifs théoriques						
Catégorie d'âge	pas de frères et soeurs	1 à 3 frères et soeurs	plus de 3 frères et soeurs	Ensemble		
18 à 30 ans	29	196	125	351		
31 à 60 ans	97	649	415	1 161		
61 ans et plus	41	273	174	488		
Ensemble	167	1118	714	2000		

Les écarts au carré rapportés à l'effectif théorique

Ainsi, la valeur du Khi2 est donnée par la formule :

$$\chi^{2} = \sum_{i,j} \frac{(\textit{Eff}^{\textit{theo}}_{i,j} - \textit{Eff}^{\textit{obs}}_{i,j})^{2}}{\textit{Eff}^{\textit{theo}}_{i,j}}$$

Tableau de contingence : écarts au carré rapportés à l'effectif théorique							
		Type de famille					
Catégorie d'âge	pas de frères et soeurs	1 à 3 frères et soeurs	plus de 3 frères et soeurs	Ensemble			
18 à 30 ans	(29 - 33) ² /29	(196 - 242) ² /196	(125 - 76) ² /125	351			
31 à 60 ans	(97 - 72) ² /97	(649 - 616) ² /649	(415 - 473) ² /415	1 161			
61 ans et plus	(41 - 62) ² /41	(273 - 260) ² /273	(174 - 166) ² /174	488			
Ensemble	167	1 118	715	2 000			

Le test statistique et la p-value associée

- La statistique de test χ^2 donne donc une mesure de l'écart à l'indépendance : jusqu'à quel point ce qu'on observe est éloigné d'une situation où il n'y aurait pas de lien entre les variables ?
- Le test statistique part de la valeur du χ^2 et la compare avec les écarts qu'on considérerait comme étant le fruit du hasard. Grâce à la loi Normale, on sait modéliser l'aléa de sous forme de probabilités, donc le risque de se tromper en concluant quelque chose à partir des écarts observés.
- L'hypothèse nulle du test est celle qu'on essaie souvent de rejeter : la catégorie d'âge et le type de famille n'ont pas de lien entre eux
- L'hypothèse alternative est celle qu'on accepte quand l'hypothèse nulle est rejetée : la catégorie d'âge et le type de famille sont bien interdépendants

Le test statistique et la p-value associée

- La p-value, c'est le plus petit niveau de risque tel qu'on peut encore rejeter l'hypothèse nulle. Au vu de la grandeur ou de la petitesse des écarts à l'indépendance mesuré par le χ^2 , est-ce qu'en affirmant qu'il y a un lien entre les variables je risque de me tromper dans 50%, dans 10% ou dans seulement 1% des cas ? En général, on prend comme niveau de risque acceptable 10% pour affirmer que la relation est significative.
- C'est un seuil arbitraire qui s'est cristallisé dans la pratique mais il n'y a aucune justification mathématique à ce niveau.
- Quand p est supérieur au seuil, c'est soit qu'il y a interdépendance, soit que votre échantillon était trop petit pour conclure avec fiabilité sur l'interdépendance des variables.
- p ne mesure pas l'intensité de la relation entre les deux variables, seulement la significativité du lien.
- **p** n'est pas la probabilité que les deux variables soient interdépendantes. C'est seulement la probabilité de se tromper en affirmant cela à partir de ce que vous avez observé!

Pearson's X^2: Rao & Scott adjustment

```
data: svychisq(formula = \sim cat_age + type_fam, design = hdv2003_ponderes) F = 10.697, ndf = 3.9378, ddf = 7871.6107, p-value = 1.523e-08
```

- La valeur du khi2 associé au tri croisé du sexe et du type de famille est inférieure à 0,1
- La p-valeur est extrêmement élevée. Il y a plus de 95% de chances de se tromper en affirmant que le sexe et la structure familiale sont interdépendants. On est dans une sorte d'impasse : on ne peut pas rejeter l'hypothèse nulle, mais on ne peut pas dire qu'elle est vérifiée!
- ▶ Un plus grand échantillon pourrait être capable d'appréhender des effets subtiles du sexe des enfants sur les comportements de fécondité des parents, par exemple si les parents cherchent à avoir un nouvel enfant quand le premier est une fille. Cela établirait *in fine* un lien entre ces deux variables qui n'est pas perceptible avec seulement 2000 enquêté·es. En l'état, on ne peut donc rien dire.

Guide d'interprétation

Les conclusions tirées des tests d'hypothèse ne concernent donc que les possibilités d'inférence de nos données. Il faut toujours se demander :

- La (non)-significativité de mes résultats est-elle surtout le fruit des catégories choisies, de la taille de mon échantillon et de la façon dont il a été constitué, ou est-elle vraisemblable d'un point de vue sociologique ? Exemple: une enquête réalisée sur internet interroge le lien entre l'âge et le fait de posséder un portable et un ordinateur. Elle trouve que les senior ne détiennent pas significativement moins d'ordinateurs et de portables que les plus jeunes.
- Est-ce que le lien statistique mis en lumière suggère un lien de causalité entre ces variables, qui a un vrai sens sociologique, ou ai-je seulement identifié une corrélation peu intéressante, qui cache une troisième variable explicative, voire fallacieuse, le lien n'étant que le pur fruit du hasard ? Exemple : une enquête par questionnaire cherche à savoir si les parisien nes ont plus souvent des accidents de voiture que les habitant es du reste du territoire français. Elle trouve au contraire que les parisien nes sont sous-représenté es parmi les accidents mineurs et graves.
- Quelles sont les connaissances sociologiques et les résultats empiriques d'autres recherches qui peuvent expliquer le lien d'interdépendance indiqué par les tests ?